

CLASSIFICAÇÃO DE CARROCERIAS DE AUTOMÓVEIS

META III – INTELIGÊNCIA COMPUTACIONAL



Pedro Saraiva – 2023146226
Daniel Soares – 2023144661

ENQUADRAMENTO DO TRABALHO

- Preparação e limpeza do dataset
 - Remoção de imagens duplicadas
 - Eliminação de imagens irrelevantes, com ruído ou baixa qualidade
- Dataset final equilibrado (5000 imagens):
 - Treino: 700 imagens por classe (total: 3500, ~70%)
 - Validação: 150 imagens por classe (total: 750, ~15%)
 - Teste: 150 imagens por classe (total: 750, ~15%)
- Reotimização do modelo
 - Nova otimização dos hiperparâmetros com Grey Wolf Optimizer (GWO)
 - Avaliação final no conjunto de teste independente
- Melhoria significativa da accuracy: ~80% → ~85%

DESCRIÇÃO DO PROBLEMA – OBJETIVOS

- Preparação de um dataset balanceado com divisão em treino, validação e teste (20%)
- Comparação entre 3 redes pré-treinadas mencionadas no enunciado: ResNet; MobileNet e EfficientNet
- Aplicação de uma dessas redes pré-treinadas ao nosso dataset
- Otimização das camadas densas superiores (top layers)
- Análise comparativa da influência de diferentes tamanhos de conjuntos de treino
- Estudo da sensibilidade aos hiperparâmetros: GWO, Grid Search e Random Search
- Implementação de uma aplicação web para classificação em tempo real

DATASET E SUB-PASTAS DE TREINO

Divisão do dataset

Conjunto	Imagens por classe	Total	Porcentagem
Treino	700	3500	70%
Validação	100	500	10%
Teste	200	1000	20%

Sub-pastas de treino

Experiência	Nº Imagens/classe	Total treino
A	150	750
B	300	1500
C	500	2500
D	700	3500

REDES PRÉ-TREINADAS AVALIADAS

Tabela de comparação do [Keras](#)

Modelo	Params	Top-1 Accuracy	Top-5 Accuracy	Tempo GPU (ms)
MobileNetV2	3.5M	71.3%	90.1%	3.8 ms
EfficientNetB0	5.3M	77.1%	93.3%	4.9 ms
ResNet50V2	25.6M	76%	93%	4.4 ms

Tabela de comparação ao nosso problema

Modelo	Tempo de treino	Melhor Accuracy - Conjunto de validação	Accuracy - Conjunto de teste	Observações
EfficientNetB0	02:01	~0.20	Erro	Falhou no teste (classificador colapsou)
MobileNetV2	01:39	0.871	0.873	Rápido e eficiente
ResNet50V2	02:26	0.902	0.906	Melhor desempenho global

ESTRATÉGIA USADA DE TRANSFER LEARNING

- Extração apenas da base convulsional da rede pré-treinada (excluindo top layers)
- Congelamento da base convulsional no treino – treinar apenas a rede densa
- Construção da rede densa:
 - GlobalAveragePooling2D
 - Dense(units/neurónios) com ReLU
 - Dropout
 - Dense(5, softmax)
- Posteriormente otimizar hiperparâmetros destas camadas densas

MÉTODOS DE OTIMIZAÇÃO

- Otimização de:
 - N° neurónios da camada densa
 - Dropout
 - Learning rate
- Grey Wolf Optimizer (Swarm)
 - → neurónios: [128, 256, 512]; dropout: 0.30 a 0.70; lr: 0.00001 a 0.001
- Grid Search
 - → neurónios: [128, 256, 512, 1024]; dropout: [0.30, 0.40, 0.50, 0.60, 0.70]; lr: [0.00001, 0.00003, 0.0001, 0.0003, 0.001, 0.003, 0.01]
- Random Search
 - → neurónios: [128, 256, 512]; dropout: 0.30 a 0.70; lr: 0.00001 a 0.001

COMPARAÇÃO I – SUB-TREINOS 150 A 700 IMAGENS POR CLASSE


150	<pre> ===== OTIMIZAÇÃO GWO COMPLETA em 1.46 horas ===== [FICHEIRO] Resultados completos da otimização guardados em: gwo_results_resnet_train150.csv A ler melhor resultado do JSON para re-treino final... Melhor Accuracy (Validação): 0.866000 Melhor conjunto de Hiperparâmetros: units: 256 lr: 0.000878 dropout: 0.397728 ===== </pre>	300	<pre> ===== OTIMIZAÇÃO GWO COMPLETA em 1.99 horas ===== [FICHEIRO] Resultados completos da otimização guardados em: gwo_results_resnet_train300.csv A ler melhor resultado do JSON para re-treino final... Melhor Accuracy (Validação): 0.880000 Melhor conjunto de Hiperparâmetros: units: 512 lr: 0.000760 dropout: 0.393886 ===== </pre>
500	<pre> ===== OTIMIZAÇÃO GWO COMPLETA em 3.82 horas ===== [FICHEIRO] Resultados completos da otimização guardados em: gwo_results_resnet_train500.csv A ler melhor resultado do JSON para re-treino final... Melhor Accuracy (Validação): 0.908000 Melhor conjunto de Hiperparâmetros: units: 256 lr: 0.000738 dropout: 0.444528 ===== </pre>	700	<pre> ===== OTIMIZAÇÃO GWO COMPLETA em 5.70 horas ===== [FICHEIRO] Resultados completos da otimização guardados em: gwo_results_resnet_train700.csv A ler melhor resultado do JSON para re-treino final... Melhor Accuracy (Validação): 0.934000 Melhor conjunto de Hiperparâmetros: units: 512 lr: 0.000432 dropout: 0.438623 ===== </pre>

COMPARAÇÃO 2 – SUB-TREINOS 150 A 700 IMAGENS POR CLASSE

150




300



500



700




COMPARAÇÃO 3 – SUB-TREINOS 150 A 700 IMAGENS POR CLASSE


150




300




500



700



COMPARAÇÃO 4 – SUB-TREINOS 150 A 700 IMAGENS POR CLASSE



COMPARAÇÃO I – OTIMIZADORES: GWO, GRID E RANDOM NA PASTA DE TREINO COM 700 IMAGENS

GWO
(Swarm)

```
=====
OTIMIZAÇÃO GWO COMPLETA em 5.78 horas
=====
[FICHEIRO] Resultados completos da otimização guardados em: gwo_results_resnet_train700.csv
A ler melhor resultado do JSON para re-treino final...
Melhor Accuracy (Validação): 0.934000
Melhor conjunto de Hiperparâmetros:
units: 512
lr: 0.000432
dropout: 0.438623
=====
```

Random
Search


```
=====
[RANDOM] OTIMIZAÇÃO COMPLETA em 6.14 horas
=====
[RANDOM][FICHEIRO] Resultados completos guardados em: random_results_resnet_train700.csv
[RANDOM] A ler melhor resultado do JSON para re-treino final...
Melhor Accuracy (Validação): 0.930000
Melhor conjunto de Hiperparâmetros (RANDOM):
units: 256
lr: 0.000314
dropout: 0.568830
=====
```

Grid Search


```
=====
[GRID] OTIMIZAÇÃO COMPLETA em 5.46 horas
=====
[GRID][FICHEIRO] Resultados completos guardados em: grid_results_resnet_train700.csv
[GRID] A ler melhor resultado do JSON para re-treino final...
Melhor Accuracy (Validação): 0.934000
Melhor conjunto de Hiperparâmetros (GRID):
units: 512
lr: 0.000300
dropout: 0.500000
=====
```

COMPARAÇÃO 2 – OTIMIZADORES: GWO, GRID E RANDOM NA PASTA DE TREINO COM 700 IMAGENS


GWO (Swarm)




Grid Search




Random Search



COMPARAÇÃO 3 – OTIMIZADORES: GWO, GRID E RANDOM NA PASTA DE TREINO COM 700 IMAGENS



COMPARAÇÃO 4 – OTIMIZADORES: GWO, GRID E RANDOM NA PASTA DE TREINO COM 700 IMAGENS



AVALIAÇÃO NO CONJUNTO DE TESTE

Confusion matrix

	Convertible	Coupe	SUV	Sedan	Van
Convertible	196	3	1	0	0
Coupe	4	163	1	32	0
SUV	1	0	193	5	1
Sedan	0	27	7	165	1
Van	0	0	4	0	196

Actual \ Predicted

Accuracy: 0.913

Relatório (precisão, recall(sensibilidade), f-measure):


	precision	recall	f1-score	support
Convertible	0.9751	0.9800	0.9776	200
Coupe	0.8446	0.8150	0.8295	200
SUV	0.9369	0.9650	0.9507	200
Sedan	0.8168	0.8250	0.8209	200
Van	0.9899	0.9800	0.9849	200
accuracy			0.9130	1000
macro avg	0.9127	0.9130	0.9127	1000
weighted avg	0.9127	0.9130	0.9127	1000

Especificidade por classe:

Convertible: 0.9938
 Coupe: 0.9625
 SUV: 0.9838
 Sedan: 0.9537
 Van: 0.9975

Macro AUC (OvR): 0.9893

WEB APP



CONCLUSÕES

- O uso de Transfer Learning demonstrou clara eficácia, superando a CNN da Meta II e permitindo obter elevada accuracy com menor esforço de treino ($\sim 85\% \rightarrow 92\%$).
- ResNet50V2 destacou-se como a melhor arquitetura, apresentando maior capacidade representativa e melhor equilíbrio entre desempenho e robustez.
- A análise dos sub-treinos revelou que a redução do número de imagens por classe (150, 300 e 500) não comprometeu significativamente a performance.
- A limitação no número de imagens de qualidade disponíveis impediu a avaliação com conjuntos de treino mais extensos.
- É plausível que, com mais dados, fosse possível confirmar que menos de 700 imagens por classe seriam suficientes ou até alcançar melhores resultados.
- Na otimização de hiperparâmetros, o Grey Wolf Optimizer (GWO) apresentou resultados mais consistentes e estáveis face ao Grid Search e ao Random Search.
- A aplicação web desenvolvida permitiu validar o modelo em ambiente real, reforçando a aplicabilidade prática da solução proposta.